

Chapitre 6 : Introduction aux modèles linéaires généralisés

Dans tout ce qui a précédé, on a cherché à prédire

- une réponse **Y numérique**,
- à l'aide de covariables X_1, \dots, X_p **numériques**.

Et on a vu comment revenir à des covariables numériques si initialement catégorielles.

Dans ce chapitre, on va s'intéresser à deux autres cas :

- (i) $Y \in \{0, 1\}$ est **binaire** (Exemples : sain/malade ; remboursera/fera défaut ; républicain/démocrate, etc.)
- (ii) $Y \in \mathbb{N}$ est un **comptage** (Exemples : nombres d'enfants ; nombres de décès causés par... ; nombres de buts dans un match)

Dans ces deux cas, l'hypothèse du **modèle linéaire gaussien**, à savoir

$$[Y|X_{1:p}] \sim \mathcal{N}(\mu(X_{1:p}), \sigma^2),$$

n'est pas réaliste. Il faut donc en changer. En outre, on rappelle que, dans le

modèle linéaire gaussien, on a

$$\mathbb{E}(Y|X_{1:p}) = \mu(X_{1:p}) = \beta_0 + \sum_j \beta_j X_j.$$

On va donc regarder deux modèles.

(i) Si $Y \in \{0, 1\}$ est **binnaire**, il faut supposer que

$$[Y|X_{1:p}] \sim \mathcal{B}(\mu(X_{1:p})).$$

(ii) si $Y \in \mathbb{N}$ est un **comptage**, on va supposer que

$$[Y|X_{1:p}] \sim \mathcal{P}(\mu(X_{1:p})).$$

Dans les deux cas,

$$\mathbb{E}(Y|X_{1:p}) = \mu(X_{1:p})$$

mais on ne va pas supposer que cette espérance conditionnelle est de la forme $\beta_0 + \sum_j \beta_j X_j$ car il y a des **contraintes** :

- (i) $0 \leq \mu(X_{1:p}) \leq 1$ dans le cas de la loi de Bernoulli ou
- (ii) $\mu(X_{1:p}) \geq 0$ dans le cas de la loi de Poisson.

1 Régression logistique

On s'intéresse ici au premier cas, où $Y \in \{0, 1\}$ est **binaire**, et on suppose que

$$[Y|X_{1:p}] \sim \mathcal{B}(\mu(X_{1:p})).$$

Dans ce cas, $\mu(X_{1:p}) = \mathbb{E}(Y|X_{1:p}) = \mathbb{P}(Y = 1|X_{1:p}) \in [0; 1]$.

La fonction logistique est définie, pour tout $x \in]0; 1[$ par

$$\begin{aligned} \text{logit} :]0; 1[&\rightarrow \mathbb{R} \\ x &\mapsto \log\left(\frac{x}{1-x}\right). \end{aligned}$$

C'est une bijection strictement croissante de $]0; 1[$ sur \mathbb{R} , infiniment dérivable. Et la fonction inverse est donnée par

$$\begin{aligned} \text{logit}^{-1} : \mathbb{R} &\rightarrow]0; 1[\\ x &\mapsto \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}} \end{aligned}$$

qui est infiniment dérivable. Voici le graphe de cette fonction.




Figure 1 – Graphe de la fonction logit^{-1} , et sa tangente en $x = 0$

L'**hypothèse linéaire** devient maintenant

$$\text{logit}(\mu(X_{1:p})) = \beta_0 + \sum_j \beta_j X_j.$$

Autrement dit,

$$\begin{aligned}\mathbb{E}(Y|X_{1:p}) &= \mathbb{P}(Y = 1|X_{1:p}) = \text{logit}^{-1}\left(\beta_0 + \sum_j \beta_j X_j\right) \\ &= \frac{1}{1 + \exp\left(-\beta_0 - \sum_j \beta_j X_j\right)} \in]0; 1[.\end{aligned}$$

Le **rapport de cote** (ou *odds ratio*) vaut alors

$$\frac{\mathbb{P}(Y = 1|X_{1:p})}{\mathbb{P}(Y = 0|X_{1:p})} = \exp(\beta_0) \prod_{j=1}^p \exp(\beta_j X_j).$$

Ce qui revient à supposer un **effet multiplicatif** des covariables sur le rapport de cote. En effet, toute autre covariable étant fixée, remplacer X_j par $X_j + 1$ revient à multiplier le rapport de cote par $\exp(\beta_j)$.

Avec des données $\mathbf{Y} \in \{0, 1\}^n$ et $\mathbf{X} \in \mathbb{R}^{n \times p}$, on ajuste le modèle par **maximum de vraisemblance**. Ce maximum est n'est pas explicite, il faut utiliser un algorithme d'optimisation numérique pour le trouver (Newton-Raphson). Ici, la vraisemblance est

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}, \quad \text{où } p_i = \frac{1}{1 + \exp(-\beta_0 - \sum_j \beta_j X_{ij})}.$$

On note $\hat{\beta}$ l'estimateur du maximum de vraisemblance.

Pour un **nouvel individu** de covariables $\tilde{X}_1, \dots, \tilde{X}_p$ connues et de réponse \tilde{Y} inconnue, on peut **inférer/prédire** deux quantités différentes :

- la probabilité de la réponse 1, ou la réponse moyenne, à savoir $\mu(\tilde{X}_{1:p}) = \mathbb{P}(\tilde{Y} = 1 | \tilde{X}_{1:p})$, avec

$$\hat{\mu}(\tilde{X}_{1:p}) = \frac{1}{1 + \exp\left(-\hat{\beta}_0 - \sum_j \hat{\beta}_j \tilde{X}_j\right)}$$

- la réponse \tilde{Y} elle-même, avec

$$\hat{Y} = \begin{cases} 1 & \text{si } \hat{\mu}(\tilde{Y} | \tilde{X}_{1:p}) > 0.5 \\ 0 & \text{sinon} \end{cases}$$

2 Régression de Poisson

Rappel. Si $Z \sim \mathcal{P}(a)$, alors,

$$\forall k \in \mathbb{N}, \quad \mathbb{P}(Z = k) = e^{-a} \frac{a^k}{k!} \quad \text{et} \quad \mathbb{E}(Z) = a.$$

2.1 Exposition constante

On s'intéresse ici au second cas, où $Y \in \mathbb{N}$ est un **comptage**, et on suppose que

$$[Y|X_{1:p}] \sim \mathcal{P}(\mu(X_{1:p})).$$

Dans ce cas, $\mu(X_{1:p}) = \mathbb{E}(Y|X_{1:p}) \in [0; +\infty[$.

Dans la régression de Poisson, la fonction **logarithme** va jouer le même rôle que la fonction logistique et on suppose que

$$\log \mu(X_{1:p}) = \log \mathbb{E}(Y|X_{1:p}) = \beta_0 + \sum_j \beta_j X_j.$$

Avec des données $\mathbf{Y} \in \mathbb{N}^n$ et $\mathbf{X} \in \mathbb{R}^{n \times p}$, on ajuste le modèle par **maximum de vraisemblance**. Ce maximum est n'est pas explicite, il faut utiliser un algorithme d'optimisation numérique pour le trouver (Newton-Raphson). Ici, la vraisemblance est

$$L(\beta) = \prod_{i=1}^n e^{-a_i} \frac{a_i^{y_i}}{y_i!}, \quad \text{où } a_i = \exp(\beta_0 + \sum_j \beta_j X_{ij}).$$

On note $\hat{\boldsymbol{\beta}}$ l'estimateur du maximum de vraisemblance.

Pour un **nouvel individu** de covariables $\tilde{X}_1, \dots, \tilde{X}_p$ connues et de réponse \tilde{Y} inconnue, on peut **inférer/prédire** deux quantités différentes :

- la réponse moyenne, à savoir $\mu(\tilde{X}_{1:p}) = \mathbb{E}(\tilde{Y} \mid \tilde{X}_{1:p})$, avec

$$\hat{\mu}(\tilde{X}_{1:p}) = \exp\left(\hat{\beta}_0 + \sum_j \hat{\beta}_j \tilde{X}_j\right)$$

- la réponse \tilde{Y} elle-même, avec

$$\hat{Y} = G\left(\hat{\mu}(\tilde{X}_{1:p})\right)$$

où, pour tout $a > 0$,

$$G(a) = \operatorname{argmax}_{k \in \mathbb{N}} e^{-a} \frac{a^k}{k!}.$$

Notons ici que $G(a)$ est la modalité la plus probable de la loi $\mathcal{P}(a)$.

2.2 Avec durée d'exposition variable

Une variable aléatoire de Poisson Z peut être un comptage **pendant une durée donnée $D > 0$** . (Exemple : nombre d'accident pendant une certaine durée). On suppose alors que

$$\mathbb{E}(Z|D) = aD, \quad \text{où } a \text{ est une nombre moyen par unité de temps.}$$

Donc,

$$\log \mathbb{E}(Z|D) = \log a + \log D.$$

Dans le modèle de Poisson avec durée d'exposition variable, on va donc supposer que

$$\log \mathbb{E}(Y|D, X_{1:p}) = \beta_0 + \sum_j \beta_j X_j + \log D.$$

Alors,

- $E = \log D$ intervient dans la formule comme une covariable, mais le coefficient en facteur est connu, égal à 1,
- $\exp(\beta_0 + \sum_j \beta_j X_j)$ est le nombre moyen par unité de temps (à covariables fixées).

L'ajustement se fait également par maximum de vraisemblance. La précision des estimateurs n'est pas liés au nombres d'observations, mais à la durée totale d'exposition

$$n_D = D_1 + D_2 + \dots + D_n.$$

3 Exemples

3.1 Régression logistique simple

On s'intéresse à l'élection présidentielle américaine en 1992 qui opposait Georges W. Bush et Bill Clinton (vainqueur). S'ajoute un troisième candidat sans étiquette Ross Perot. Pour étudier le vote d'un électeur, on pose

$$Y = \begin{cases} 1 & \text{si vote en faveur de Bush} \\ 0 & \text{sinon} \end{cases}$$

On dispose d'une variable explicative $X \in \{1, 2, \dots, 5\}$ qui indique le niveau de revenu de l'électeur. (Pauvre $\iff X = 1$). Données : 14031 votants.

Table 1 – Fréquence des votes par classes de revenus ($Y = 1$ si vote Bush)

income	1	2	3	4	5
%($Y = 1$)	41	44	49	54	70
%($Y = 0$)	59	56	51	46	30

Si on ajuste un modèle de régression logistique sur ces données, on obtient

$$\text{logit}(\mathbb{P}(Y = 1|X)) \approx -0.67 + 0.23X.$$

On peut représenter l'ajustement avec la figure ci-dessous.




Figure 2 – Ajustement sur l'élection de 1992

Comment s'interprète 0.23 ? Quand on remplace $\text{income} = x$ par $\text{income} = x+1$, le **rapport de cote** est multiplié par

$$\exp(0.23) \approx 1.25.$$

Et les prédictions sont

Table 2 – Fréquence des votes par classes de revenus ($Y = 1$ si vote Bush)

income	1	2	3	4	5
données %($Y = 1$)	41	44	49	54	70
prédictions $\hat{\mu}$	0.39	0.44	0.50	0.56	0.62

3.2 Nombre d'accidents de la route

On souhaite prédire le nombre d'accidents de la route aux carrefours par année en fonction de deux covariables :

- X_1 , vitesse moyenne en km/h des voitures sur les routes autour du carrefour,

- X_2 , présence de feu tricolore au carrefour.

Avec des données, on a ajusté le modèle

$$\log \mathbb{E}(Y | X_1, X_2, D) \approx 2.8 + 0.02X_1 - 0.20X_2 + \log D.$$

Interprétations :

- Si on augmente la vitesse moyenne de 10 km/h sans changer X_2 , le nombre moyen d'accidents par années est multiplié par $\exp(0.02 \times 10) \approx 1.22$. D'où une augmentation du nombre moyen d'environ 22%.
- Si on ajoute un feu tricolore sans changer X_1 , le nombre moyen d'accidents par années est multiplié par $\exp(-0.2) \approx 0.82$. D'où une diminution de 18% du nombre moyen d'accidents.