

Correction rapide de l'examen de Modèle linéaire 2021/2022

Le barème est donné à titre indicatif.

Les trois exercices portent sur le même jeu de données concernant la région de Boston. Il contient les informations ci-dessous sur 506 quartiers de cette métropole.

Pour chacun des quartiers, on a :

- `crim` : taux de criminalité du quartier (nombre d'infractions criminelles pour 10000 habitants pour 1 an)
- `zn` : proportion de terrains résidentiels formés de propriétés de plus de 2300 mètres-carrés
- `indus` : proportion du quartier occupée par des zones industrielles
- `chas` : le quartier est-il en bordure de la rivière Charles (modalités : “Yes” ou “No”)
- `nox` : concentration annuelle moyenne en oxyde d'azote (polluant, unité : ppm)
- `rm` : nombre moyen de pièces par logement
- `age` : proportion de logements occupés par leurs propriétaires et construits avant 1940
- `dis` : distance moyenne aux cinq principaux bassins d'emploi de Boston
- `rad` : temps d'accès moyen depuis un logement jusqu'aux grands axes de circulation (en minutes)
- `tax` : taux d'impôt foncier du quartier
- `ptratio` : rapport nombre d'élèves sur nombre d'enseignants dans les écoles du quartier
- `lstat` : proportion de la population de classe inférieure
- `logmv` : logarithme de la valeur moyenne (en milliers de dollars US) des logements

Exercice 1 (≈ 7 points)

Dans cet exercice, on souhaite prédire la variable $Y = \log(\text{crim})$, qui est le logarithme de la variable `crim`.

1.1 On introduit la covariable $X_1 = \text{rad}/10$ et on ajuste le modèle

$$Y = \beta_0 + \beta_1 X_1 + \varepsilon.$$

Les résultats obtenus sont la table 1. Quelle est la part de variabilité de Y expliquée par X_1 ? Rappeler la définition de la quantité que vous utilisez pour répondre à cette question. Quelle quantité définie au niveau de la population estime-t-elle ?

73% de variabilité est expliquée...

$$R^2 = \text{SSR}/\text{SST}, \text{ où } \text{SST} = \sum(y_i - \bar{y})^2, \text{ SSR} = \sum(\hat{y}_i - \bar{y})^2.$$

$$\text{Elle estime } R_{\text{pop}}^2 = \beta_1^2 \text{Var}(X)/\text{Var}(Y) = \text{Cor}^2(X, Y).$$

1.2 Écrire R^2 en fonction de $\hat{\sigma}^2$, l'estimation de la variance de l'erreur, et $\hat{s}_y^2 = (n-1)^{-1} \sum_{i=1}^n (y_i - \bar{y})^2$, l'estimation de la variance de Y .

$$R^2 = 1 - \text{SSE}/\text{SST} = 1 - (n-2)\hat{\sigma}^2 / (n-1)s_y^2.$$

1.3 Les distributions des variables Y et X_1 sont représentées dans la figure 1. Les résultats numériques de cette première régression sont dans la table 1. Comment s'interprète la valeur estimée de β_1 ? Les intervalles de confiances sont-ils utilisables avec ces informations?

β_1 : augmentation de la prédiction de Y (la log-criminalité) lorsque rad (temps d'accès grands axe) est augmenté de 10 unité.

IC : la figure 1 ne permet pas de conclure

Table 1 – Régression de la log-criminalité en fonction de rad

	$\hat{\beta}_i$	$\text{sd}(\hat{\beta}_i)$	int. confiance (95%)
Intercept	-2.80	0.07	[-2.95; -2.66]
$\text{rad}/10$	2.12	0.06	[2.00; 2.24]
$R^2 \approx 0.73$	$R_{\text{adj}}^2 \approx 0.73$	$\hat{\sigma}^2 \approx 1.128$	$\hat{s}_y^2 \approx 4.674$

1.4 La figure 2 donne différentes représentations graphiques. Commentez rapidement ces graphiques, et complétez les réponses fournies précédemment.

Figure 2 gauche : résidus presque gaussiens. Donc IC à peu près justes.

Figure 2 milieu : peu de valeurs extrêmes, pas de courbe régulière

Figure 2 droite : un gros trou dans les valeurs observées de $\text{rad}/10\dots$

1.5 Donnez une estimation du nouveau coefficient β_{rad} si l'unique covariable du modèle est $\text{rad} = 10X_1$.

$\beta_{\text{rad}} = \hat{\beta}_1/10$ pour que le produit βx ne change pas.

1.6 On introduit la variable $X_2 = \text{lstat}/10$ et on s'intéresse au modèle

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{1:2} X_1 X_2 + \epsilon.$$

Mettez X_1 en facteur des deux termes où il apparaît, et constatez que la quantité en facteur de X_1 (son effet) dépend linéairement de X_2 .

$$Y = \beta_0 + (\beta_1 + \beta_{1:2} X_2) X_1 + \beta_2 X_2 + \epsilon.$$

1.7 Les résultats numériques sont donnés dans la table 2. On admet que les hypothèses qui justifient les intervalles de confiance sont vérifiées. Commenter les valeurs estimées des coefficients β_1 , β_2 et $\beta_{1:2}$. En particulier, comment comprenez-vous le signe de la valeur estimée de $\beta_{1:2}$?

Table 2 – Régression multiple de la log-criminalité

	$\hat{\beta}_i$	sd($\hat{\beta}_i$)	int. confiance (95%)
Intercept	-3.93	0.14	[-4.20; -3.66]
rad/10	2.12	0.13	[1.97; 2.50]
lstat/10	1.14	0.11	[0.92; 1.36]
(rad/10) × (lstat/10)	-0.28	0.08	[-0.44; -0.13]
	$R^2 \approx 0.79$	$R^2_{\text{adj}} \approx 0.79$	

$$\beta_1 \approx 2 > 0$$

$$\beta_2 \approx 1 > 0$$

$$\beta_{1:2} \approx -0.3 < 0$$

À X_2 fixé, l'effet de l'augmentation d'une unité de X_1 dépend de X_2 et vaut $\approx \beta_1 + \beta_{1:2} X_2$. Cet effet diminue à mesure que X_2 est grand ($\beta_{1:2} < 0$).

On peut aussi factoriser sous la forme

$$Y = \beta_0 + \beta_1 X_1 + (\beta_2 + \beta_{1:2} X_2) X_2 + \epsilon.$$

À X_2 fixé, l'effet de l'augmentation d'une unité de X_2 dépend de X_2 et vaut $\approx \beta_2 + \beta_{1:2} X_1$. Cet effet diminue à mesure que X_1 est grand ($\beta_{1:2} < 0$).

Exercice 2 (≈ 6 points)

On souhaite maintenant prédire $Y = \text{logmv}$ à l'aide des 12 autres variables du jeu de données. Les corrélations entre toutes les variables sont données dans la figure 3, à gauche.

2.1 La variable `chas` est catégorielle. Comment peut-on l'inclure dans un modèle linéaire ?

deux modalités \implies une variable binaire (par exemple, `=1` \iff `chas=Yes`)

2.2 En utilisant la partie gauche de la figure 3, donnez la corrélation entre les variables `rad` et `tax`. Commentez.

0.91. Cette valeur est grande. Elle va perturber l'inférence par moindres carrés car présence de forte corrélation dans les covariables.

2.3 On note \mathbb{X} la matrice du plan d'expérience (la première colonne est composée de 1, ...) et \mathbb{Y} le vecteur colonne des valeurs observées de $Y = \text{logmv}$. On note $\beta = (\beta_0, \beta_1, \dots, \beta_{12})$ le vecteur des effets et σ^2 la variance du terme d'erreur. En supposant que les erreurs sont gaussiennes, écrire la log-vraisemblance $\ell(\beta, \sigma^2)$ en fonction de ces quantités.

$$\ell(\beta, \sigma^2) = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \left\| \mathbb{Y} - \mathbb{X}\beta \right\|_2^2 + \text{constante}$$

2.4 On pose $\beta_{-0} = (\beta_1, \dots, \beta_{12})$. On s'intéresse à la méthode Lasso, où

$$\hat{\beta}(\lambda) = \operatorname{argmin}_{\beta} \left\| \mathbb{Y} - \mathbb{X}\beta \right\|_2^2 + \lambda \|\beta_{-0}\|_1.$$

À quoi sert-elle ?

A forcer l'annulation de coordonnées de l'estimation

2.5 Les différentes estimations $\hat{\beta}(\lambda)$ et la valeur $\hat{\lambda}$, choisie par validation croisée, sont représentées à droite de la figure 3. À la aide de cette figure, répondre aux trois questions ci-dessous.

- (a) Donnez le nom d'une variable v pour laquelle l'estimation $\hat{\beta}_v(\hat{\lambda})$ est nulle.
- (b) Quelle est la variable v pour laquelle l'estimation $\hat{\beta}_v(\hat{\lambda})$ est la plus grande en valeur absolue ? Quel est son signe ?
- (c) Quand λ augmente, le coefficient $\hat{\beta}_{\text{tax}}(\lambda)$ en facteur de tax décroît vers 0 en valeur absolue, puis s'éloigne de 0 au moment où $\hat{\beta}_{\text{rad}}(\lambda)$ s'annule. Que se passe-t-il ?

- (a) rad, zn age
- (b) Istat, signe <0
- (c) ces deux variables sont fortement corrélées (voir quest 1). La disparition de rad est compensée...
+ zn qui s'annule et qui est négativement corrélé avec rad et tax (-0.31)

Exercice 3 (≈ 7 points)

Comme dans l'exercice 2, on souhaite prédire $Y = \text{logmv}$ à l'aide des 12 autres variables du jeu de données. **On suppose dans cet exercice que les 12 covariables numériques sont transformées pour être centrées-réduites.**

3.1 La méthode de sélection de variable rétrograde, partant du modèle complet, appliquée sur le critère BIC, donne les résultats de la table 3. La variable nox indique un niveau de pollution. Comment interprétez-vous les résultats quant à cette pollution ?

Table 3 – Régression multiple de logmv obtenu par critère BIC

	$\hat{\beta}_i$	sd($\hat{\beta}_i$)	int. confiance (95%)
Intercept	3.0345	0.0092	[3.0165;3.0525]
lstat	-0.2300	0.0143	[-0.2581;-0.2019]
ptratio	-0.0768	0.0112	[-0.0988;-0.0548]
dis	-0.0854	0.0147	[-0.1142;-0.0566]
nox	-0.0795	0.0176	[-0.1141;-0.0449]
rm	0.0685	0.0120	[0.0449;0.0921]
chasYes	0.0341	0.0094	[0.0157;0.0526]
tax	-0.0403	0.0141	[-0.0679;-0.0127]
$R^2 \approx 0.75$		$R^2_{\text{adj}} \approx 0.74$	

Toute chose étant égale par ailleurs, augmentation de la pollution fait baisser les prix (effet < 0, voir IC)

3.2 En partant du modèle complet à 12 covariables, la première variable éliminée dans cette méthode rétrograde est la variable age. Est-ce lié au choix du critère BIC ?

Non. Pour comparer des modèles de même dimension, c'est-à-dire à 11 covariables, on n'utilise que le R^2

3.3 Dans quel contexte utilise-t-on plutôt BIC que AIC ? Que peut-on dire de la covariable `zn` qui n'a pas été retenue par le modèle de la table 3, mais que le critère AIC propose de conserver ?

BIC = explicatif AIC = prédictif

`zn` : Ne gène pas, ou améliore un peu les qualités prédictives d'un modèle linéaire. Mais, sachant les autres covariables déjà incluses, l'influence de `zn` sur les prix n'est pas clairement établie...

3.4 La méthode progressive, appliquée au critère BIC, choisit le même modèle à 7 covariables que celui de la table 3. Cette égalité entre les modèles retenu par la méthode progressive et la méthode rétrograde est-elle attendue systématiquement ou est-ce un résultat spécifique à ce jeu de données ?

spécifique. On a vu des cas de différence en TP.

3.5 La première variable introduite par la méthode progressive est `lstat`. Peut-on le justifier avec la matrice de corrélation de la figure 3 ? (On attend ici une réponse argumentée.)

Dans la méthode progressive, pour la première covariable, on choisit la covariable avec le plus grand $R^2 = \text{Cor}^2(Y, X_i)$.

Toutes les autres cor avec logmv sont < 0.81 en valeur absolue.

3.6 On note X_1, \dots, X_7 les variables aléatoires qui modélisent les 7 covariables de la table 3. Et Y celle qui modélise la réponse. Que vaut (justifier)

$$\mathbb{E}(Y|X_1 = x_1, \dots, X_7 = x_7) ?$$

Comment estimez-vous cette quantité pour des valeurs numériques de x_1, \dots, x_7 données ?

$$\begin{aligned}\mathbb{E}(Y|X_1 = x_1, \dots, X_7 = x_7) &= \mathbb{E}(\sum_j \beta_j X_j + \epsilon | X_1 = x_1, \dots, X_7 = x_7) \\ &= \sum_j \beta_j x_j + \mathbb{E}(\epsilon | X_1 = x_1, \dots, X_7 = x_7) \quad (\text{linéarité}) \\ &= \sum_j \beta_j x_j + \mathbb{E}(\epsilon) \quad (\epsilon \text{ indep. } X_j) \\ &= \sum_j \beta_j x_j.\end{aligned}$$

Estimation :

$$\sum_j \hat{\beta}_j x_j.$$




Figure 1 – Distribution des variables $\text{rad}/10$ à gauche, $\text{lstat}/10$ au milieu et $\log(\text{crim})$ à droite.




Figure 2 – Étude du modèle linéaire simple $\log(\text{crim}) = \beta_0 + \beta_1 \text{rad}/10 + \epsilon$. À gauche, histogramme des résidus normalisés et densité de la loi normale centrée réduite en rouge. Au milieu, résidus normalisés en fonction de $\hat{\beta}_0 + \hat{\beta}_1 X_1$. À droite, $\log(\text{crim})$ en fonction de $\text{rad}/10$, et droite de régression ajustée sur les données.




Figure 3 – À gauche, matrice de corrélation des variables du jeu de données. Les croix \times représentent des corrélations non significativement différentes de 0.

À droite, représentation de l'estimation $\hat{\beta}_i(\lambda)$ des coefficients par la **méthode Lasso** (sur l'axe des ordonnées) en fonction du paramètre de réglage λ (sur l'axe des abscisses). La droite verticale en pointillés correspond à la valeur $\hat{\lambda}$ choisie par validation croisée.